

PLANEJAMENTO DA EXPANSÃO DE SISTEMAS DE TRANSMISSÃO DE ENERGIA ELÉTRICA UTILIZANDO REDES BAYESIANAS¹

Mateus Ribeiro da SILVA²

Graduado em Engenharia de Controle e Automação
IFSP/Câmpus São Paulo

Muriell de Rodrigues e FREIRE³

Doutor em Engenharia Elétrica/UNIFEI
Docente de Engenharia de Controle e Automação
IFSP/Câmpus São João da Boa Vista

RESUMO

Este trabalho tem como objetivo estudar a aplicação de Redes Bayesianas (RB) no problema do Planejamento da Expansão da Transmissão (PET). A formulação do PET foi baseada no planejamento de longo prazo, considerando o critério de segurança N-1. As melhores soluções para o problema foram encontradas através de um algoritmo evolutivo especialista e usadas para a aprendizagem das RB. Analisou-se a utilização das RBs em estudos de caso, chegando-se a conclusão que tais redes possuem grande potencial para a aplicação no problema PET, pois, através dessas redes, foi possível realizar planejamentos de maneira prática e flexível, cumprindo, assim, o propósito do trabalho, que é encontrar planos de expansão que sejam interessantes para a realidade das empresas do setor elétrico.

Palavras-chave: Algoritmo Evolutivo; Redes Bayesianas; Planejamento da Expansão da Transmissão de Longo Prazo.

Introdução

O Planejamento da Expansão da Transmissão (PET) é um problema clássico encontrado na área de estudo de Sistemas Elétricos de Potência. Tal problema tem como objetivo encontrar solução ótima para o plano de expansão de um determinado sistema

¹ Artigo resultante de Trabalho de Conclusão de Curso em Engenharia de Controle e Automação. Orientador Prof. Dr. Muriell de Rodrigues e Freire.

² Endereço eletrônico: mateus.ribe.sva@gmail.com

³ Endereço eletrônico: muriell@ifsp.edu.br

de transmissão de energia elétrica, do qual deve possibilitar a manutenção e a operação adequada. Sendo assim, tendo-se levantado dados sobre um possível cenário de expansão da linha de transmissão elétrica, o PET fornece informações sobre a quantidade e a localidade onde serão instalados os equipamentos para reforço da linha de transmissão. É importante mencionar que o PET, além de fornecer as informações citadas, também objetiva encontrar a solução com menor custo de investimento e que atenda as especificações de qualidade e segurança (SILVA; FREIRE; HONÓRIO, 2016).

A resolução do problema de PET é uma tarefa de complexidade considerável mesmo quando não são consideradas as incertezas de um sistema real (tais como crescimento da carga, localização de geradores, etc.) e, por se tratar de um problema combinatório estocástico, o uso de técnicas computacionais que aperfeiçoem o espaço de busca das possíveis soluções para o PET possui grande utilidade. Dentre as vantagens que algoritmos de otimização de busca trazem, estão: a eficiência da exploração do espaço de busca, o tolhimento de ótimos locais e o custo computacional relativamente baixo (SILVA; FREIRE; HONÓRIO, 2016). Embora este trabalho faça uso de um algoritmo evolutivo adaptativo baseado em multioperadores de busca, há diversas abordagens de resolução propostas para os problemas de PET.

Técnicas de otimização baseadas numa abordagem meta-heurística têm ganhado destaque por demonstrarem boa performance em obter soluções ótimas com um custo computacional relativamente baixo. Os modelos seguem um método de resolução de problema que consiste no processo de geração de uma população, seguindo para uma avaliação através das funções que definem a aptidão de um candidato dentro da população para um determinado problema e, após, faz-se a seleção dos melhores candidatos. As vantagens que abrangem esse tipo de técnica são: a simplicidade relativa dos algoritmos e a busca global inteligente que evita a escolha de ótimos locais.

Os modelos meta-heurísticos podem ser divididos em dois grandes grupos, sendo eles os algoritmos de enxames e os algoritmos evolutivos (SILVA *et al.*, 2011). Este trabalho não vai tratar detalhadamente dos algoritmos de enxame, mas é importante mencionar que este modelo aborda, basicamente, o comportamento coletivo de sistemas, baseando-se, muitas vezes, na estrutura comportamental dos insetos (SERAPIÃO, 2009). Os algoritmos evolutivos utilizam-se de recursos probabilísticos


para realizarem a simulação do processo biológico de evolução natural: reprodução, mutação, recombinação (do inglês, *crossover*) e seleção. Existe uma ampla variedade de algoritmos evolutivos, alguns exemplos são: *Differential Evolution* (DE) (DONG; LU, M.; LU, Z., 2006), *Artificial Immune Systems* (AIS) (REZENDE *et al.*, 2009), *Genetic Algorithms* (GA) (SILVA; FREIRE; HONÓRIO, 2016).

Todo algoritmo evolutivo possui uma população de candidatos a solução, e cada candidato possui uma série de características que serão utilizadas para medir seu grau de adaptação (do inglês, *fitness*) através de uma função. Após a medição da adaptação de cada candidato, é formada uma nova população contendo os melhores candidatos, enquanto que alguns candidatos podem sofrer alguma alteração nas suas características através de mutação ou *crossover* (tais processos podem tanto melhorar as características do candidato quanto piorar o *fitness* do mesmo). O algoritmo iterativamente até que se atinja a condição de parada, podendo ser esta atendida de diversas formas. Na maioria dos casos, a condição de parada é atendida quando se atinge o número máximo de gerações (iteração) ou quando se encontra um candidato que represente a solução ótima do problema (SILVA *et al.*, 2011).

As Redes Bayesianas são ferramentas gráficas representadas por grafos acíclicos que mostram as relações de dependência que existem entre as variáveis. Tais grafos possuem dois elementos principais chamados de nós e arcos. Os nós são representados por círculos e servem para indicar a variável, discreta ou contínua, do problema. Os arcos são setas que indicam uma dependência probabilística direta entre duas variáveis (COSTA, 2013). Considerando um caso em que há dois nós X e Y, diz-se que se uma aresta sai de X para Y significa que X é um nó pai de Y, desta forma existindo uma relação condicional entre os dois. No geral, para um nó A_i , existe uma distribuição de probabilidade condicional associada sendo representada pela equação $P(A_i | \text{pai}(A_i))$ (RUSSELL; NORVIG, 1995).

A estrutura de uma Rede Bayesiana é mostrada na Fig. 1. Analisando a situação demonstrada pela Rede, pode-se dizer que o nó ‘acidente’ está relacionado com todos os nós antecedentes, estando diretamente relacionado ao ‘estrada molhada’ e ao ‘velocidade’. Os nós ‘chuva’ e ‘radar’ são independentes, pois não dependem de nenhuma variável. Com uma visão geral, pode-se inferir que, caso chova e a velocidade seja alta, a probabilidade de um acidente acontecer é grande (PELIKAN *et al.*, 2002).

Figura 1 — Estrutura de Rede Bayesiana



Fonte: Adaptado de Pelikan *et al.* (2002)

O processo de aprendizado das Redes Bayesianas é um muito importante para o BOA, pois, para que o algoritmo possua uma boa eficiência, é necessário que as RBs representem, de maneira correta e resumida, as dependências e independências do problema. No aprendizado das Redes, há dois principais processos que influenciam na qualidade delas, sendo eles: aprendizagem da estrutura e aprendizagem dos parâmetros. O primeiro processo é responsável pelo posicionamento das arestas na Rede e, desta forma, dizer quais são as dependências entre as variáveis. Já o segundo diz respeito ao valor das probabilidades condicionais das variáveis (PELIKAN *et al.*, 2002).

Com a obtenção da Rede Bayesiana, é possível extrair informações e verificar possíveis situações, como foi o caso do exemplo anterior, no qual se supôs que, com a chuva, a estrada ficaria molhada e assim se aumentaria o risco de um acidente. Este processo de extrair conhecimento das Redes é chamado de inferência e tem como base a propagação de evidências. Através da propagação de evidências, é possível obter uma informação atualizada do conhecimento da Rede a partir das inferências impostas a ela por meio de fatos fornecidos (DOS SANTOS, 2007). As Redes Bayesianas têm sido utilizadas em várias áreas do conhecimento, tais como: Defesa Aérea (SANTOS; NÓBREGA, 2016), Biologia Computacional para estudo de câncer (ADABOR; ACQUAAH-MENSAH, 2019), Agricultura (DRURY *et al.*, 2017) etc.

Tendo-se em vista o horizonte de aplicação das Redes Bayesianas, este trabalho tem como objetivo geral realizar estudo da aplicação de Redes Bayesianas no problema da expansão da transmissão de energia elétrica considerando o critério de segurança “N-1” e dessa maneira estudar uma nova abordagem que possui potencial para fornecer

soluções para o PET mais flexíveis e adaptáveis a situações reais. Para este trabalho, serão analisados os modelos de sistemas de transmissão de Garver e de IEEE RTS-79.

Desenvolvimento

O presente trabalho tem um caráter quantitativo que busca analisar a aplicabilidade dos resultados das Redes Bayesianas em problemas de PET, como mencionado anteriormente. Para realizar essa análise, o trabalho foi dividido em três etapas principais, sendo elas: coleta de dados, aprendizado das Redes Bayesianas e análise das Redes Bayesianas.

A coleta de dados diz respeito à aquisição dos melhores planos de expansão para um determinado sistema de transmissão. Neste trabalho, foram utilizados dois sistemas de transmissão para análise. O sistema Garver é um clássico para resolução do PET, contendo 6 barras e 15 ramos candidatos, sendo, assim, considerado um sistema acadêmico de pequeno porte. O sistema IEEE RTS – 79 também é amplamente utilizado para fins acadêmicos e possui 24 barras e 41 ramos candidatos (FREIRE, 2016).

A aquisição dos dados se dará a partir do algoritmo evolutivo especialista AES-TEP (SILVA; FREIRE; HONÓRIO, 2016), visando adquirir os 10 melhores planos de expansão para cada taxa de relaxamento (critério que varia de 0% a 20%). Cada plano retorna o número de reforços necessários em cada ramo do sistema proposto, além de fornecer o custo de investimento do plano de expansão da transmissão.

Para encontrar os 10 melhores planos possíveis, foram realizadas, de forma exaustiva, diversas simulações para cada critério e sistema de transmissão. Após a finalização do processo de busca das melhores soluções, foi exportado o arquivo TXT que continha os dados necessários para o aprendizado das Redes Bayesianas.


Tendo sido adquirido o banco de dados contendo todas as soluções para cada sistema de transmissão proposto, foi utilizado o software GeNIe 2.3 *Academic*, fornecido pela empresa BayesFusion, LLC®, a fim de se realizar o aprendizado das Redes Bayesianas.

O primeiro passo para realizar o aprendizado foi a importação de dados no software. Antes de efetuar o processo de busca das Redes, foi necessário que todos os

dados possuíssem um caráter discreto, pois o algoritmo utilizado não lida com dados contínuos. Caso existam variáveis contínuas, basta utilizar a opção de discretização fornecida pelo próprio software.

Após a importação e tratamento dos dados, executou-se o aprendizado das Redes Bayesianas utilizando o algoritmo *Bayesian Search*. Na Fig. 2, é mostrada a janela de ajuste dos parâmetros para o algoritmo.


Figura 2 — Ajuste de parâmetros do algoritmo *Bayesian Search*



Fonte: Autores

Tendo sido concluído o processo de aprendizado da Rede, o software retornou o grafo contendo as relações condicionais entre as variáveis, assim como os parâmetros utilizados e a métrica de pontuação da Rede. Com tais informações, foram feitas inferências e análises para verificar a aplicabilidade da Rede para o sistema proposto. Na Fig. 3, é mostrado o resultado do aprendizado de uma Rede teste.

Figura 3 — Rede Bayesiana de teste



Fonte: Autores

A qualidade da Rede Bayesiana é influenciada diretamente pelo ajuste de parâmetros (parâmetros de controle do algoritmo de busca e da métrica de avaliação das Redes). Portanto, a busca por uma Rede ideal exige diversas simulações com variação dos valores dos parâmetros: nota-se que, para cada caso de estudo, existe um bom conjunto de valores.


Resultados obtidos

Nesta seção, serão discutidos alguns estudos de caso a fim de se entender e justificar a aplicação das Redes Bayesianas para o PET.

A primeira análise que será feita refere-se à força de influência que determinados nós pais exercem nas probabilidades dos nós filhos, resultando numa relação causa-efeito.

A Rede Bayesiana (Fig. 4) será utilizada para analisar a ferramenta disponibilizada pelo GeNIe chamada *Strength of Influence* que permite visualizar de maneira fácil e intuitiva o grau de influência que determinado nó exerce num nó vizinho. Os parâmetros para a aprendizagem da Rede Bayesiana encontram-se na Fig. 4.


Figura 4 — Rede Bayesiana Garver sem inferências



Fonte: Autores

O diagrama fornece-nos arestas que possuem sua espessura diretamente relacionada com a força de influência que um nó exerce no outro (causa- efeito). A análise foi iniciada pelo nó ‘Ramo4a6’, que é pai do nó ‘Ramo2a6’, e apresenta sobre ele uma grande influência. Foi inferido que esse ramo teve um total de três reforços e observa-se na Fig. 5 que a decisão afetou, de maneira relevante, os valores do ‘Ramo2a6’.


Figura 5 — Rede Bayesiana Garver com inferências



Fonte: Autores

Após a inferência feita no Ramo4a6, foi inferido que o Ramo2a6 não receberá nenhum reforço na linha. Ressalte-se que o Ramo2a6 é pai do nó Custo e que Custo possui diversos nós filhos. Deste modo, a inferência realizada pelo Ramo2a6 afeta uma grande parte da Rede (Fig. 6). Através deste estudo, pôde-se verificar que o diagrama de influência serviria para guiar o planejador numa possível sequência de decisões a serem tomadas durante o planejamento de um sistema.

Figura 6 — Rede Bayesiana Garver final




Fonte: Autores

O próximo estudo de caso que será abordado tem como objetivo a extração de um plano já existente (banco de dados) a partir de inferências realizadas.

Na Fig. 7, é mostrada a estrutura da Rede Bayesiana assim como os parâmetros utilizados para encontrá-la. É importante mencionar que o parâmetro que define a quantidade máxima de pais que um nó terá (do inglês, *max parent count*) influencia diretamente a densidade da Rede e, conseqüentemente, a qualidade dela. Uma Rede densa expressa os dados por ela aprendidos de maneira mais fiel, porém, quanto maior a densidade da Rede, maior será a dificuldade de interpretá-la. Por isso, é importante a busca por uma Rede que não seja tão densa, mas que também não seja tão simples a ponto de se perderem algumas informações importantes. Sendo assim, a Rede encontrada abaixo foi o resultado mais balanceado encontrado para análise.


Figura 7 — Rede Bayesiana Garver para planejamento sem inferências



Fonte: Autores

Para se realizarem as inferências, foi considerado o critério de selecionar as evidências com probabilidade maior que 60%. Seguindo este critério e considerando uma taxa de relaxamento de 10%, chegou-se à Rede presente na Fig. 8.

Figura 8 — Rede Bayesiana Garver para planejamento com inferências



Fonte: Autores


Nota-se que foi encontrado o plano 30 da Tab. 1, que contém os planos de expansão do sistema Garver. Este plano possui uma similaridade muito grande com o plano de ID 29. Destarte, a fim de verificar se a Rede consegue representar a base de dados de maneira eficaz, foram realizadas inferências nos nós Ramo2a6 e Ramo4a6 para se obter o plano 29. Sendo feitas as inferências, o plano desejado foi encontrado como previsto (Fig. 9).

Tabela 1 — Planos de Expansão do Sistema Garver para taxa de relaxamento (Tx) de 10%

1a	1a	1a	2a	2a	2a	2a	3a	3a	3a	4a	5a	Custo
2	3	5	3	4	5	6	4	5	6	6	6	o
0	0	0	1	0	0	1	0	2	0	3	0	180
0	0	0	0	0	0	3	0	2	0	2	0	190
0	0	0	0	0	1	1	0	2	0	3	0	191
1	0	0	0	0	0	1	0	2	0	3	0	200
0	0	0	0	1	0	3	0	2	0	1	0	200
0	0	0	0	0	0	2	0	2	1	2	0	208
0	1	0	0	0	0	2	0	3	0	2	0	218
0	0	0	2	0	0	0	0	2	1	3	0	218
0	0	0	0	0	0	3	1	2	0	2	0	219
0	0	0	0	0	0	3	1	2	0	1	0	219

Fonte: Autores

Figura 9 — Rede Bayesiana Garver para planejamento final




Fonte: Autores

Como análise de estudo de caso final, foi desenvolvida uma situação hipotética de planejamento a fim de compreender melhor a aplicação das Redes Bayesianas numa

situação prática de definição de um plano de expansão. Para realizar o planejamento, foi utilizada a Rede da Fig. 10.


Figura 10 — Rede Bayesiana IEEE para planejamento sem inferências



Fonte: Autores

Para o início do planejamento, foi considerado um critério de relaxamento de 5%. Percebe-se que os nós Ramo19a23, Ramo2a8 e Ramo19a20 são independentes, por esta razão, as inferências feitas neles não surtiram efeito no resto da Rede. Diante disso, foi suposto que tivessem algum reforço no planejamento a fim de se economizar com instalações e futuras manutenções. Prosseguindo com as tomadas de decisão, foi escolhido seguir algumas probabilidades de ramos que não precisassem de reforço. A partir disso, os nós que possuíam uma probabilidade maior que 80% de reforço 0 foram inferidos, chegando-se à Rede da Fig. 11.


Figura 11 — Rede Bayesiana IEEE para planejamento com inferências



Fonte: Autores

A Rede acima indica alguns ramos que apresentam alta probabilidade de serem reforçados, como por exemplo, o nó Ramo6a10 que possui grande tendência a ser reforçado com 2 linhas. Porém, devido a existência de problemas socioeconômicos e políticos, os nós Ramo3a9, Ramo4a9, Ramo12a23 e Ramo1a3 não poderão ser reforçados.


Figura 12 — Rede Bayesiana IEEE para planejamento



Fonte: Autores

Após serem feitas as devidas inferências, chegou-se à Rede da Fig. 12. Nota-se que alguns ramos ficaram com tendências claras de reforço possuindo probabilidades acima de 90% e que foram inferidas essas tendências.

Figura 13 — Rede Bayesiana IEEE para planejamento



Fonte: Autores

Percebe-se, pela análise da Rede acima (Fig. 13), que a margem de custo do planejamento já está definida no intervalo de 633 a 662 milhões de reais. Então, levando-se em conta que a margem está de acordo com o orçamento previsto, não há necessidade de se realizar nenhum reforço em quaisquer ramos que não foram inferidos. Sendo assim, foi inferido que os nós restantes não foram reforçados, chegando-se à Rede final presente na Fig. 14.

Analisando-se o plano hipotético que foi encontrado através das inferências feitas na Rede Bayesiana (Tab. 3), nota-se que tal plano tem similaridade com o plano destacado na Tab. 2, que possui um custo de 641 milhões de reais. Com tal informação, pode-se dizer que a margem de custo de 633 a 662 milhões de reais encontrada pela Rede condiz com os planos da base de dados. Sendo assim, pode-se concluir que a Rede conseguiu realizar a mineração de dados necessária para condensar todo o conteúdo do banco de dados fornecido à ela e assim possibilitar as tomadas de decisões para se chegar a planos mais flexíveis e com maior custo-benefício para o planejador.

Tabela 2 — Planos de Expansão IEEE RTS-79 para taxa de relaxamento (Tx) de 5%

1a 3	1a 5	2a 4	2a 6	3a 9	4a 9	6a 10	9a 11	9a 12	10 a1 1	10 a1 2	11 a1 3	12 a1 3	12 a2 3	14 a1 6	20 a2 3	1a 8	2a 8	13 a1 4	14 a2 3	Custo
0	2	0	0	2	1	2	1	0	1	0	2	0	0	1	1	0	0	0	1	615
0	2	0	0	2	1	2	0	1	1	0	1	1	0	1	1	0	0	0	1	615
0	1	0	0	2	1	2	1	0	1	0	2	0	0	1	1	0	1	0	1	626
0	1	0	0	2	1	2	1	0	1	0	2	0	0	1	1	1	0	0	1	628
0	1	0	0	2	1	2	0	1	1	0	1	1	0	1	1	1	0	0	1	628
1	2	0	0	1	1	2	1	0	1	0	2	0	0	1	1	0	0	0	1	639
1	2	0	0	1	1	2	0	1	1	0	1	1	0	1	1	0	0	0	1	639
0	2	1	0	2	0	2	0	1	0	1	1	0	1	0	2	0	0	1	0	641
0	1	0	1	2	1	2	1	0	1	0	2	0	0	1	1	0	0	0	1	643
0	1	0	1	2	1	2	0	1	1	0	1	1	0	1	1	0	0	0	1	643


Fonte: Autores

Tabela 3 — Plano de Expansão encontrado pela Rede Bayesiana

2a	6a1	9a1	10a1	11a1	20a2	13a1
4	0	2	1	3	3	4
1	1	1	1	1	1	1

Fonte: Autores

Figura 14 — Rede Bayesiana IEEE para planejamento final



Fonte: Autores

Conclusão

As Redes Bayesianas (RBs) possuem um extenso leque de aplicações em diversas áreas do conhecimento, isto porque são responsáveis por interpretar um certo conjunto de dados e apresentá-los numa forma gráfica e dinâmica. Tendo-se isto em mente, o intuito deste trabalho foi analisar a aplicação das RBs para um problema clássico do setor elétrico (problema PET com critério de segurança N-1), e assim verificar se tais Redes possuem potencial uso para projetistas que atuam neste ramo.

Pela observação dos aspectos analisados, pode-se dizer que a utilização de Redes Bayesianas no PET possui um claro horizonte de aplicação prática. Foi observado que estas Redes propiciam um ambiente gráfico e amigável para o planejador realizar as inferências desejadas, e assim analisar um plano de expansão que atenda a todos os requisitos do projeto, incluindo os problemas sociais, políticos e legislativos que assolam a expansão da linha de transmissão elétrica. As RBs servem como uma ferramenta gráfica para planejamento interativo, mesclando a experiência do usuário com a mineração de dados obtida via simulações computacionais.

Vale ressaltar que os sistemas de potência utilizados neste trabalho foram provindos de modelos acadêmicos (Garver e IEEE). Sendo assim, a utilização de modelos reais e com maior complexidade pode ser uma sugestão de pesquisas futuras para complementar este trabalho.

Referências

ADABOR, E. S.; ACQUAAH-MENSAH, G. K. Restricted-derestricted dynamic bayesian network inference of transcriptional regulatory relationships among genes in cancer. *Computational Biology and Chemistry*, [s. l.], v. 79, p. 155-164, 2019.

COSTA, Felipe Schneider. **Aprendizagem estrutural de redes bayesianas pelo método de Monte Carlo e cadeias de Markov**. 2013. Dissertação (Mestrado em Ciência da Computação) — Universidade Federal de Santa Catarina, Santa Catarina, 2013.

DONG, Z. Y.; LU, M.; LU, Z. A differential evolution based method for power system planning. In: *EEE INTERNATIONAL CONFERENCE ON EVOLUTIONARY*

DOS SANTOS, Edimilson Batista. A ordenação das variáveis no processo de otimização de classificadores bayesianos: uma abordagem evolutiva. 2007. 114 f.

Dissertação (Mestrado em Ciências Exatas e da Terra) - Universidade Federal de São Carlos, São Carlos, 2007.

COMPUTATION, 2006, Vancouver. **Anais** [...]. Vancouver: IEEE, 2006. p. 2699-2706.

DRURY, B. et al. A survey of the applications of Bayesian networks in agriculture. *Engineering Applications of Artificial Intelligence*, [s. l.], v. 65, p. 29-42, 2017.

FREIRE, Muriell de Rodrigues e. **Algoritmo evolutivo adaptativo via multioperadores aplicado ao planejamento da expansão de sistemas de transmissão**. 2016. Tese (Doutorado em Engenharia Elétrica) — Universidade Federal de Itajubá, Itajubá, 2016.

PELIKAN, M.; SASTRY, K.; GOLDBERG, D. E. Scalability of the Bayesian optimization algorithm. *International Journal of Approximate Reasoning*, v. 31, n. 3, p. 221–258, nov. 2002.

REZENDE, L. S.; LEITE DA SILVA, A. M.; HONORIO, L. M. Artificial Immune Systems and Differential Evolution Based Approaches Applied to Multi-Stage Transmission Expansion Planning. 2009 15th International Conference on Intelligent System Applications to Power Systems. *Anais...* In: 2009 15TH INTERNATIONAL CONFERENCE ON INTELLIGENT SYSTEM APPLICATIONS TO POWER SYSTEMS (ISAP). Curitiba, Brazil: IEEE, nov. 2009. Disponível em: <<http://ieeexplore.ieee.org/document/5352957/>>. Acesso em: 23 abr. 2019.

RUSSELL, S. J.; NORVIG, P. **Artificial intelligence: a modern approach**. Englewood Cliffs: Prentice Hall, 1995

SANTOS, G. Q.; NÓBREGA, M. D. J. R. Aplicação da Rede Bayesiana na área de defesa. **Revista Augustus**, Rio de Janeiro, v. 20, n. 40, p. 46–55, 2016.

SERAPIÃO, A. B. S. Fundamentos de otimização por inteligência de enxames: uma visão geral. *Controle & Automação: Revista da Sociedade Brasileira de Automática*, [s. l.], v. 20, n. 3, p. 271-304, 2009.

SILVA, A. M. L. *et al.* Performance comparison of metaheuristics to solve the multi-stage transmission expansion planning problem. *IET Generation, Transmission & Distribution*, [s. l.], v. 5, n. 3, p. 360-367, 2011.

SILVA, A. M. L.; FREIRE, M. R.; HONÓRIO, L. M. Transmission expansion planning optimization by adaptive multi-operator evolutionary algorithms. **Electric Power Systems Research**, [s. l.], v. 133, p. 173-181, 2016.

**ELECTRIC POWER TRANSMISSION SYSTEMS EXPANSION PLANNING USING
BAYESIAN NETWORKS**

ABSTRACT

This work aims to study the application of Bayesian Networks (BN) in the Transmission Expansion Planning (TEP) problem. The TEP's formulation will be based in the long term planning, considering the security criteria N-1. The besto solutions about TEP problem were found by expert evolutionary algorithm and used to the BN's learning. It was analyzed the use of RB's in case studies, reaching the conclusion that such networks have great potential for applications in TEP problems, because, through these networks, it was possible to perform planning in practical and flexible ways, thus reaching the purpose of this work, which is looking for expansion plans that are interesting to the reality of electric sector's companies.

Keywords: Evolutionary Algorithm; Bayesian Networks; Long Term Transmission Network Expansion Planning.

Envio em: janeiro/2020
Aceito para publicação: abril/2020